

UNIVERSITATEA BABEȘ-BOLYAI CLUJ-NAPOCA
FACULTATEA DE MATEMATICĂ ȘI INFORMATICĂ
SPECIALIZAREA Informatică Română

LUCRARE DE LICENȚĂ

Lucrare Licență Pușcaș Raul

Conducător științific
Conferențiar, Dr. Bufnea Darius

Absolvent
Pușcaș Raul-Andrei

ABSTRACT

Recunoașterea automată a numerelor de înmatriculare reprezintă procesul de extragere și recunoaștere a caracterelor care formează identificatorul unic al unui vehicul.

Sistemul de recunoaștere captează imaginea prin intermediul unei camere (B/W, Infraroșu etc), pe care o trimite mai departe unei unități de procesare care execută un algoritm format din 3 etape: localizarea numărului de înmatriculare, segmenatarea caracterelor, recunoașterea caracterelor. Ulterior, informația extrasă poate fi folosită în cadrul unor servicii precum: securizarea parcărilor, monitorizarea traficului, etc.

Comparat cu abordările existente ale probleme evoluția prezentată în această lucrare se evidențiază prin reziliența pe care o oferă față de diferiții factori care pot afecta calitatea sistemului: condiții de lumină variabile, diferite formate ale plăcuței de înmatriculare, reziduuri care pot obscura caracterele. Dar și prin nivelul ridicat de optimizare adus întregului proces.

Cuprins

1	Introducere	1
1.0.1	Contextul aplicației	2
2	Localizarea numărului de înmatriculare	4
2.0.1	Algoritmi bazați pe detectarea contururilor	5
3	Segmentarea imaginii	9
3.0.1	Conectivitatea pixelilor	9
3.0.2	Analiza proiecțiilor	9
3.0.3	Utilizarea informațiilor apriori privind aspectul caracterelor . .	10
3.0.4	Analiza conturului caracterelor	10
4	Recunoașterea caracterelor	11
5	Implementarea sistemului	16
5.1	Tehnologii	16
5.1.1	Nucleu	17
5.1.2	Nivelul de aplicație	17
5.2	Detalii tehnice	17
5.2.1	Input	18
5.2.2	Fluxul de procesare	18
5.2.3	Nivelul aplicație	18
6	Concluzii	19
	Bibliografie	20

Capitolul 1

Introducere

Datorită numărului din ce în ce mai crescut de autoturisme puse în circulație anual, crearea și dezvoltarea unui sistem de recunoaștere automată a numerelor de înmatriculare, a identificatorului unic atașat fiecărui vehicul este cu atât mai mare. Un astfel de sistem este are aplicații în securizarea parcărilor, blocarea accesului în interiorul zonelor protejate de lege și monitorizarea traficului. Un exemplu concret ar fi localizarea unui autoturism pierdut. Fără ajutorul unui sistem automat, pentru a reuși această misiune ar fi necesară intervenția și colaborarea a unui număr ridicat de persoane, care în ciuda efortului lor ar putea produce un rezultat eronat datorită faptului că este pur și simplu dificil să citim și să reținem numărul de înmatriculare al unui vehicul aflat în mișcare.

Sistemele de recunoaștere automată a numărului de înmatriculare (ALPR) sunt cunoscute și sub numele de: identificare automată a vehiculelor (AVI), recunoaștere optică a caracterelor (OCR) pentru autoturisme. Variația plăcuțelor și a mediului în care se face recunoașterea cauzează provocări procesului de detectare și identificare:

1. Variații ale plăcuței

- Locația: Plăcuțele pot apărea în diferite segmente ale imaginii
- Cantitatea: O imagine poate conține mai multe plăcuțe
- Mărimea: Plăcuțele pot avea mărimi diferite datorită diferitelor formate, dar și a distanței față de cameră
- Culoarea: Numerele de înmatriculare din diferite țări pot fi scrise pe diferite culori
- Fontul: Numerele de înmatriculare din diferite țări pot fi scrise folosind diferite fonturi
- Obscuare: Plăcuțele pot fi murdare

2. Mediul înconjurător

- Luminozitate: Cadrele capturate pot varia în nivelul de luminozitate în mare parte datorită luminii din mediul înconjurător și a celei de la faruri
- Fundalul: Fundalul imaginii poate conține tipare similare cu cele găsite pe numărul de înmatriculare

Din punct de vedere arhitectural, se poate forma o taxonomie a acestor sisteme în care principalele 2 categorii sunt: sisteme de tip multi-etapă sau singură etapă/ procesare directă. Mai mult, în interiorul categoriilor mai pot fi făcute separări suplimentare: sistemele de tip multi etapă diferă prin diferitele tehnici aplicate în cadrul fiecărei etape a procesului: localizarea plăcuței de înmatriculare, segmentarea caracterelor și într-un final recunoașterea caracterelor; în cele de tip procesare directă diferențierea se face la nivelul arhitecturii modelului și a diferitelor tehnici de optimizare aplicate.

1.0.1 Contextul aplicației

Studiul prezentat în această lucrare a fost motivat de cerințele concrete ale dezvoltării unui sistem de control al accesului auto pentru o parcare situată pe teritoriul României. În acest scenariu, sistemul trebuie să fie capabil să recunoască în mod fiabil o varietate largă de plăcuțe de înmatriculare, întrucât în fluxul cotidian de trafic se regăsesc atât numere uzuale, de tip județ–două cifre–trei litere (de exemplu, CJ 12 ABC), cât și plăcuțe temporare cu serie roșie (format provizoriu), plăcuțe pentru autoturisme noi cu format CJ 123 ABC, plăcuțe diplomatice (cod CD, TC, CO), plăcuțe pentru vehicule speciale aparținând Ministerului Afacerilor Interne sau Ministerului Apărării Naționale, precum și plăcuțe străine ale autovehiculelor aflate în tranzit. Această diversitate ridicată în privința formatului, a paletelor cromatice de fond, a dimensiunilor relative și a fontului caracterelor reprezintă un factor determinant în selectarea metodologiei de procesare. Tocmai din aceste motive, în prezenta lucrare a fost exclusă de la bun început orice abordare bazată pe segmentarea culorii (color-based segmentation), deși aceasta este frecvent utilizată în literatură pentru regiuni geografice cu plăcuțe standardizate cromatic. Lucrări reprezentative precum [1], care exploatează caracteristicile cromatice ale plăcuțelor taiwaneze, sau [2] pentru spațiul autohton al insulei Taiwan, demonstrează eficacitatea acestor metode atunci când mediul de operare prezintă o uniformitate cromatică ridicată. Generalizarea acestor abordări către scenariul nostru ar fi necesitat menținerea unui catalog de palete pentru fiecare format admis, ceea ce ar fi introdus o sursă suplimentară de erori și ar fi diminuat capacitatea de adaptare a sistemului la plăcuțele atipice sau la formatele nou introduse de către autorități. O a doua constrângere fundamentală a aplicației o reprezintă regimul de timp real

în care sistemul trebuie să opereze. Deoarece bariera de acces trebuie acționată într-un interval de cel mult 1–2 secunde de la momentul în care vehiculul ajunge în fața camerei de captură, întregul flux de procesare – de la achiziția cadrului, localizarea plăcuței, segmentarea caracterelor și până la recunoașterea și validarea numărului împotriva bazei de date a abonaților – trebuie să se încadreze într-un buget temporal strict, măsurat în zeci de milisecunde. Aceste constrângeri elimină utilizarea directă a modelelor profunde neoptimizate, care, pe hardware modest, depășesc cu ușurință pragul acceptabil de latență, și impun fie o abordare clasică, fie utilizarea unor arhitecturi compacte, optimizate pentru platforma de execuție disponibilă la nivelul punctului de acces. Dincolo de scenariul concret descris, problema generală a sistemelor ALPR prezintă o importanță practică considerabilă într-o gamă largă de domenii. Aplicațiile tipice includ:

- Managementul parcarilor publice și private, prin automatizarea proceselor de tarificare, gestionare a abonamentelor și monitorizare a gradului de ocupare
- Monitorizarea și controlul traficului urban, inclusiv aplicarea automată a sancțiunilor pentru depășirea vitezei legale sau pătrunderea în zone cu acces restricționat
- Securizarea perimetrelor sensibile (instituții publice, unități militare, baze logistice, campusuri industriale), prin compararea automată a numărului identificat cu o listă de acces
- Sistemele de taxare automată pe autostrăzi și poduri cu plată, prin asocierea numărului recunoscut cu un cont al utilizatorului
- Gestionarea flotelor auto comerciale și logistice, prin urmărirea în timp real a vehiculelor în interiorul depozitelor și terminalelor
- Identificarea autovehiculelor furate sau implicate în acțiuni infracționale, prin integrarea sistemelor de captură cu bazele de date ale autorităților

Această diversitate de scenarii explică interesul susținut al comunității de cercetare pentru îmbunătățirea continuă a metodelor de detecție și recunoaștere, atât din perspectiva acurateții, cât și a eficienței computaționale și a robusteții în condiții reale de operare.

Capitolul 2

Localizarea numărului de înmatriculare

Detectarea corectă și precisă a plăcuței de înmatriculare (LP) în interiorul imaginii este o secțiune critică a întregului proces. Regiunea determinată de LP poate fi localizată folosind diferite metode care pot fi clasificate în funcție de caracteristica utilizată: culoare, textură, sau contur. Ultima categorie este întâlnită cel mai frecvent în aplicații și se bazează pe presupunerea că în interiorul LP-ului există schimbări de intensitate mai drastice și mai dese decât în oricare altă zonă a imaginii. Metodele bazate pe culoare au ca fundație presupunerea că există o distincție clară între culoarea numărului de înmatriculare și fundal; iar cele pe textură se folosesc de prezența caracterelor în interiorul LP-ului pentru a delimita regiunea acestuia.

Precum am menționat când am definit contextul aplicației, există o diversitate ridicată în privința formatului, a paletii cromatice de fond, a dimensiunilor relative și a fontului caracterelor. Tocmai din aceste motive, în prezenta lucrare a fost exclusă de la bun început orice abordare bazată pe segmentarea culorii (color-based segmentation), deși aceasta este frecvent utilizată în literatură pentru regiuni geografice cu plăcuțe standardizate cromatic. Lucrări reprezentative precum [1], care exploatează caracteristicile cromatice ale plăcuțelor taiwaneze, sau [2] pentru spațiul autohton al insulei Taiwan, demonstrează eficacitatea acestor metode atunci când mediul de operare prezintă o uniformitate cromatică ridicată. Generalizarea acestor abordări către scenariul nostru ar fi necesitat menținerea unui catalog de paliete pentru fiecare format admis, ceea ce ar fi introdus o sursă suplimentară de erori și ar fi diminuat capacitatea de adaptare a sistemului la plăcuțele atipice sau la formatele nou introduse de către autorități

Metodele bazate pe textură deși mult mai robuste din punct de vedere al acurateței și a rezistenței față de factori externi comparat atât cu metodele bazate pe contururi cât și cele bazate pe culoare [3] care au atins o acuratețe de 98%, nu pot fi folosite mai departe în această lucrare deoarece ele se folosesc de algoritmi complexi din punct de vedere computațional care ar încălca constrângerea de timp real impusă sistemului.

2.0.1 Algoritmi bazați pe detectarea contururilor

Această abordare are la bază presupunerea că în interiorul plăcuței există o densitate ridicată de linii verticale și orizontale care fac regiunea respectivă să iasă în evidență. Indiferent de abordare ulterioară, fluxul de procesare începe întotdeauna de la transformarea imaginii în greyscale. În fotografie și viziune pe calculator, o imagine grayscale este o imagine în care fiecare pixel este o nuanță de gri, unde valoarea fiecărei celule este un singur eșantion, ținând doar informația intensității. Această caracteristică a imaginilor grayscale reprezintă un factor important, deoarece în cadrul trecerilor, mai exact la marginile unui obiect apar întotdeauna diferențe mari de intensitate, cu atât mai mult în cadrul unui număr de înmatriculare unde trecerile sunt în general de la alb la negru, roșu la alb, verde la roșu, etc. Treceri bruște, clare și evidente într-o imagine convertită la alb-negru.

În [4] asupra imaginii convertite este aplicat operatorul Sobel pentru a extrage atât marginile verticale cât și cele orizontale. Operatorul Sobel constă în 2 kernel-uri specializate pentru detectarea liniilor convoluționate asupra întregii imagini pentru a produce un rezultat care evidențiază marginile obiectelor, trecerile bruște de la o intensitate la alta. Rezultatul intermediar generat de operatorul Sobel este binarizat folosind diferiți algoritmi de prag precum metoda histogramei, grad4 etc. Pentru o localizare robustă sunt aplicate skip și integral image, primul având ca scop calcularea pentru dreptunghi de dimensiune predefinite distanța dintre pixelii albi și cei negri, iar integral image calculează pentru fiecare punct suma cumulativă a intensităților tuturor pixelilor aflați în regiunea superioară și stângă. Folosind această metodă, autorii au reușit să obțină o rată de localizare cu succes a numărului de înmatriculare de 99.95% cu un timp mediu de procesare de 47ms.





Figura 2.1: (a) Initial RGB image, (b) Binary edge detection image, (c) Skip image, (d) Integral image [4]

Similar cu [4], [5] utilizează operatorul Sobel ca componentă primară pentru extragerea marginilor și a contururilor, totuși deosebirile apar încă din etapa de pre-procesare

a imaginii (etapa de pre-procesare este formată din întreaga suită de pași aplicată imaginii înainte ca algoritmul principal de detectare a conturilor să fie rulat). [5] se folosesc de filtrul median pentru a atenua zgomotul imaginii. În viziunea pe calculator, atenuarea zgomotului presupune crearea unei funcții care capturează informațiile și tiparele imaginii lăsând la o parte detaliile la scară redusă sau alte variații rapide de intensitate.

Pe lângă filtrarea mediană, pentru a asigura un rezultat robust, autorii definesc o mască de dimensiuni predefinite preluate din condiționarea problemei asupra căreia să continue cu următoarele etape ale procesului, respectiv operatorul Sobel, binarizarea imaginii și operația morfologică de deschidere. Aceasta din urmă constă în aplicarea consecutivă a două transformări fundamentale morfologice: eroziune și dilatare.

Operația de eroziune are rolul de a diminua obiectele din prim-plan și de a elimina structurile izolate care nu aparțin plăcuței. Aceasta presupune aplicarea unui kernel asupra întregii imagini, pixelul central fiind setat ca alb dacă toți pixelii acoperiți de kernel sunt la rândul lor albi. Operația de dilatare reprezintă opusul celei de eroziune, este formată din același algoritm, însă structura sa decizională transformă pixelul evaluat în „alb” dacă cel puțin un pixel acoperit de elementul structurant este activ.



Datorită complexității ridicate a operatorului Sobel, în [6] autorii au dezvoltat un nou algoritm axat pe detectarea marginilor verticale. Alegerea de a omite marginile orizontale și de a le păstra în mod exclusiv pe cele verticale a fost fundamentată pe observația că marginile orizontale din cadrul numărului de înmatriculare pot fi confundate ușor cu grilajul radiatorului sau alte linii paralele ale caroseriei.

Fluxul de procesare propus în [6] diferă față de cele menționate anterior. Inițial, asupra imaginii greyscale îi este aplicat un algoritm de binarizare cu prag adaptiv.

Acesta este urmat de ULEA (Unwanted Line Elimination Algorithm), un procedeu

specializat de eliminare a artefactelor generate de către binarizare și a liniilor verticale nedorite de o lățime predefinită.

În final este aplicat VEDA, propus ca înlocuitor al operatorului Sobel de către autori. Această metodă constă în convoluționarea unui kernel de 2×4 asupra întregii imagini și o structură decizională care selectează un pixel ca fiind activ sau inactiv pe baza unor reguli logice în locul operațiilor clasice de convoluție.

Prin renunțarea la procesarea liniilor orizontale și optimizarea mecanismului de detecție, algoritmul propus are o viteză medie de rulare de 15ms, o îmbunătățire semnificativă în comparație operatorul Sobel care atine o viteză medie de 130ms.




Figura 2.3: Comparație între rezultatele generate de Sobel și Veda[6]

Datorită faptului că [4], [5], [6] folosesc drept componentă principală operatorul Sobel, respectiv VEDA, aceste abordări sunt capabile să localizeze plăcuțe conținând numere de înmatriculare aflate în imagine la o înclinație de până la 15° . Pentru a combate acest lucru, în [7] este folosit operatorul Hough drept selector principal.

Spre deosebire de operatorii de gradient (Sobel sau VEDA), care se bazează pe analiza locală a pixelilor, transformarea Hough reprezintă o tehnică de extracție a caracteristicilor utilizată pentru a identifica forme geometrice prin procesul de votare într-un spațiu al parametrilor. În contextul localizării numerelor de înmatriculare, aceasta este utilizată preponderent pentru detecția liniilor drepte care definesc conturul dreptunghiular al plăcuței.

Principiul fundamental constă în maparea fiecărui punct de margine (x, y) din spa-

țiul imaginii în spațiul polar (ρ, θ) , utilizând ecuația:

$$\rho = x \cos(\theta) + y \sin(\theta)$$

unde ρ reprezintă distanța perpendiculară de la origine la dreaptă, iar θ este unghiul dintre axa x și această perpendiculară.

Implementarea transformării Hough în detrimentul implementării operatorului Sobel sau VEDA aduce anumite avantaje din punct de vedere al fiabilității sistemului, acesta fiind capabil să localizeze în mod corect plăcuțe de înmatriculare înclinate la 30 ° comparat cu 15 °. De asemenea, transformarea Hough nu este atât de sensibilă la variațiile de intensitate ale imaginii, astfel că o imagine de calitate nu este imperios necesară.

Totuși, performanța sporită vine cu un cost de complexitate computațională ridicat. Deoarece procesul de votare trebuie efectuat pentru fiecare pixel de margine și pentru o gamă largă de unghiuri, consumul de memorie (pentru matricea acumulator) și timpul de procesare sunt semnificativ mai mari față de un operator de convoluție simplu precum Sobel. Din acest motiv, în sistemele de timp real, transformarea Hough este adesea aplicată pe o regiune de interes (ROI) restrânsă sau este precedată de o etapă de binarizare agresivă pentru a reduce numărul de pixeli procesați.

Capitolul 3

Segmentarea imaginii

Segmentarea imaginii joacă un rol crucial în sistemele ALPR. Procesul presupune divizarea imaginii într-un anumit număr de segmente informative, sau regiuni care sunt mai simple de studiat.

În literatura de specialitate, pentru a segmenta numărul de înmatriculare sunt propuse mai multe tehnici [8]:

- Analiza conectivității pixelilor [9]
- Analiza proiecțiilor
- Utilizarea informațiilor apriori privind aspectul caracterelor
- Analiza conturului caracterelor

3.0.1 Conectivitatea pixelilor

Această abordare presupune binarizarea regiunii de interes extrase de modulul anterior, urmată de analiza componentelor conexe(CCA) și de aplicarea unei structuri decizionale pentru filtrarea regiunilor identificare de CCA. Selecția se bazează în principal pe criterii precum similitudinea dimensiunilor și a proporțiilor zonelor identificate de CCA.

Principalul dezavantaj al acestei metode este sensibilitatea la rotație, selecția fiind realizată pe baza uniformității geometrice a regiunilor, numerele de înmatriculare rotite sau înclinate parțial sunt adesea segmentate în mod incorect.

3.0.2 Analiza proiecțiilor

Datorită contrastului ridicat dintre fundalul plăcuței și caractere, binarizarea imaginii va produce valori opuse pentru cele două. Prin urmare, numeroase metode de segmentare se bazează pe o combinație dintre analiza proiecțiilor verticale și orizontale.

În mod concret, [10] propun un sistem în care etapa de localizare se folosește de transformarea Hough pentru a corecta variația de înclinare/ rotație a lp-ului. Această aliniere permite utilizarea proiecțiilor orizontale pentru determinarea rândurilor de text.

Această abordare este extrem de utilă pentru segmentarea corectă a numerelor de înmatriculare dispuse pe mai multe rânduri (precum cele de motociclete). Separarea pe rânduri normalizează proporțiile caracterelor și dimensiunea relativă a caracterelor în raport cu sub-segmentul în care se află. În absența acestei etape, evaluare globală ar genera discrepanțe majore deoarece în cazul numerelor de înmatriculare pe un singur rând un caracter ar ocupa aproximativ 85% din înălțimea imaginii, iar pentru o plăcuță pe două rânduri ar ocupa maxim 50%.

Ulterior divizării pe rânduri, se calculează proiecțiile verticale pentru a determina pozițiile de început și de final a fiecărui caracter. Segmentele rezultate sunt supuse unui număr de constrângeri pentru a elimina diferitele elemente care pot fi segmentate în mod incorect drept caracter.

3.0.3 Utilizarea informațiilor apriori privind aspectul caracterelor

Cunoștințe apriori în legătură cu aspectul caracterelor, font-ul, mărimea și proporțiile lor pot îmbunătăți în mod significant procesul de segmentare. În [?] numărul de înmatriculare este adus la o mărime standard în care pozițiile caracterelor sunt deja cunoscute. După redimensionare, caracterele sunt extrase conform pozițiilor definite.

Această metodă presupune definirea unui modul de extrage a lp-ului robust și constant, deoarece orice deviație de la matrița definită pentru segmentare va duce la erori.

3.0.4 Analiza conturului caracterelor

O altă abordare are la bază detecția conturilor caracterelor. Pentru aceasta, în [11] este propus un proces compus din doi pași, fundamentat pe tehnici de segmentare ce utilizează metoda Fast Marching ghidată de formă (shape-driven).

Capitolul 4

Recunoașterea caracterelor

Ultima etapă, aceasta are ca scop identificarea și recunoașterea caracterelor prezente în regiunile selectate în etapa de segmentare.

General vorbind, pentru a atinge acest scop există două variante

Potrivire de șabloane

Această abordare, cunoscută sub denumirea de template matching, reprezintă metoda clasică de recunoaștere a caracterelor prin compararea directă a pixelilor. Procesul presupune existența unei baze de date cu șabloane (matrice) predefinite pentru fiecare caracter (litere și cifre), care sunt comparate succesiv cu regiunea segmentată până la identificarea celei mai bune potriviri.

Deși este eficientă din punct de vedere computațional datorită simplității algoritmice, această tehnică prezintă limitări severe în scenarii reale. Ea este aplicabilă cu succes doar atunci când caracterele extrase au dimensiuni, fonturi și grosimi constante, fiind extrem de sensibilă la variații geometrice.

Pentru a introduce un grad de robustețe și pentru a atenua sensibilitatea la zgomot sau mici distorsiuni, în locul unei suprapuneri binare perfecte, se utilizează algoritmi bazați pe calcularea distanțelor matematice între vectorii de trăsături: distanța Hamming [?], valoarea Jaccard [12].

Această metodă, deși eficientă din punct de vedere computațional, poate fi utilizată doar în situații în care regiunile de interes prezentând elementele pe care dorim să le identificăm oferă un rezultat de dimensiuni, font și caracteristici constante.

Pentru a remedia și pentru a oferi o anumită cantitate de robustozitate acestui proces, în loc de o potrivire unu la unu a elementului aflat în baza de date a matrițelor cu cel din regiunea de interes, pot fi folosiți diferiți algoritmi care calculează distanțe: , Mahalanobis. Însă în continuare marja de eroare pe care etapa anterioară își permite să o facă este una minimă.

Clasificatori statistici

Această metodă valorifică avansurile recente din domeniul inteligenței artificiale pentru a crea module de recunoaștere a caracterelor (OCR) robuste. Acestea prezintă o rezistență ridicată la variațiile de luminozitate, dimensiuni sau fonturi variate utilizate în crearea numerelor de înmatriculare, etc. În literatura de specialitate, cele mai frecvent utilizate modele pentru această etapă a procesării imaginii sunt rețelele neuronale artificiale (ANN) și mașinile pe suport vectorial (SVM), ambele prezentând avantaje și limitări specifice.

S-ar putea spune că există o oarecare similitudine între SVM și ANN deoarece ambele își au rădăcinile în algoritmul perceptronului [13], însă abordările matematice care precedă acest algoritm diferă fundamental.

Mașini pe suport vectorial

Algoritmul ce stă la baza mașinilor pe suport vectorial reprezintă o generalizare a algoritmului ”portret generalizat” dezvoltat la începutul anilor 1960 [14], [15]. Fundamentele matematice ale regresiei/ clasificării vectoriale sunt ancorate în învățarea statistică și teoria VC, care oferă o măsură a capacității de învățare a unui algoritm de învățare automată [16].

Este important de menționat că algoritmul perceptronului funcționează prin actualizarea vectorului de greutate $\mathbf{w}$ pornind de la o valoare inițială arbitrară, de regulă vectorul nul. Acesta este modificat prin adunarea exemplelor pozitive clasificate în mod eronat ca fiind negative, sau prin scăderea exemplelor negative clasificate ca fiind pozitive. Așadar, rezultatul final va fi întotdeauna o combinație liniară a punctelor din setul de antrenament.

$$\mathbf{w} = \sum_{i=1}^{\ell} \alpha_i y_i \mathbf{x}_i,$$

Unde semnul ecuației este dat de clasificarea $y_i \in \{-1, 1\}$, iar valorile α_i sunt valori pozitive proporționale cu numărul de misclasificări făcute asupra punctului în timpul stagiului de antrenament. Punctele care au cauzat mai puține erori, vor avea un α_i mai mic, iar punctele dificile unul mai mare. Date fiind aceste valori, perceptronul poate fi rescris folosind următoarea formulă:

$$h(\mathbf{x}) = \text{sgn} \left(\sum_{j=1}^{\ell} \alpha_j y_j \langle \mathbf{x}_j \cdot \mathbf{x} \rangle + b \right)$$

numită și forma duală a perceptronului.

Datorită acestei reprezentări duale, este posibilă utilizarea kernel trick-ului care ne permite maparea într-o dimensiune diferită a atributelor primite ca input. O astfel de mapare este benefică deoarece ne permite selectarea și rafinarea atributelor la un

nivel mult mai granular. Cu ajutorul kernel trick-ului, algoritmul perceptronului în formă duală nu mai depinde de calcularea explicită a vectorului de greutate în spațiul trăsăturilor, ci de evaluarea produsului scalar dintre vectorii de intrare mapați

$$f(\mathbf{x}) = \text{sgn} \left(\sum_{i=1}^{\ell} \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b \right)$$

unde $K(\mathbf{x}_i, \mathbf{x})$ reprezintă funcția kernel, definită ca produsul scalar al funcțiilor de mapare $\phi(\mathbf{x})$ (sau $\theta(\mathbf{x})$).

Teoria VC și clasificatori cu marjă maximală

Spre deosebire de algoritmul perceptronului, care se oprește în momentul în care identifică un hiperplan care separă corect punctele setului de antrenament, fără a oferi nicio garanție asupra performanței pe date nevăzute, mașinile pe suport vectorial sunt fundamentate teoretic pe principiul minimizării riscului structural derivat din teoria Vapnik-Chervonenkis (VC) [16].

Conceptul central al acestei teorii îl constituie dimensiunea VC, o măsură a capacității de exprimare a unei familii de funcții de clasificare. În mod formal, dimensiunea VC reprezintă cardinalitatea celui mai mare set de puncte care poate fi etichetat (pulverizat) în toate modurile binare posibile de către funcțiile clasei respective. O dimensiune VC ridicată indică un model cu o capacitate sporită de a se mula pe orice configurație a datelor, dar și un risc proporțional crescut de supra-învățare, deoarece marja garantată între eroarea empirică (pe setul de antrenament) și eroarea reală (așteptată pe distribuția datelor) crește odată cu dimensiunea VC. În consecință, controlul acestei dimensiuni reprezintă o cerință esențială pentru asigurarea capacității de generalizare a modelului.

În cazul particular al hiperplanelor în spațiul $\mathbb{R}^n$, dimensiunea VC este, în general, $n + 1$. Totuși, dacă restrângem familia clasificatorilor la submulțimea hiperplanelor care separă datele cu o marjă γ și presupunem că punctele de antrenament sunt incluse într-o sferă de rază R , atunci dimensiunea VC efectivă a clasei rezultate este mărginită superior de raportul R^2/γ^2 [16], [17]. Această observație fundamentală oferă justificarea teoretică pentru abordarea adoptată de SVM: prin maximizarea marjei γ , se reduce implicit dimensiunea VC a familiei de funcții utilizate, ceea ce conduce la limite superioare mai stricte asupra erorii de generalizare, independent de dimensionalitatea spațiului trăsăturilor.

Formal, problema clasificatorului cu marjă maximală se reduce la rezolvarea problemei de optimizare convexă:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{cu restricția} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, \ell,$$

unde minimizarea normei $\|\mathbf{w}\|$ este echivalentă cu maximizarea marjei $\gamma = 1/\|\mathbf{w}\|$. Această proprietate este deosebit de relevantă în contextul recunoașterii caracterelor de pe plăcuțele de înmatriculare, deoarece spațiile de trăsături utilizate (vectori obținuți prin caracteristici HOG, momente Zernike sau pixeli normalizați) sunt frecvent înalt dimensionale, iar capacitatea unui clasificator de a evita supra-învățarea într-un astfel de regim este critică.

Pentru a permite tratarea seturilor de date care nu sunt liniar separabile, formularea originală a fost extinsă prin introducerea variabilelor de relaxare ξ_i și a parametrului de penalizare C [18], conducând la formularea cu marjă moale:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^{\ell} \xi_i \quad \text{cu restricția} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Parametrul C controlează raportul dintre maximizarea marjei și tolerarea erorilor de clasificare, permițând astfel un compromis explicit între capacitatea modelului și riscul empiric. Combinat cu utilizarea funcțiilor kernel introduse prin [19], acest cadru permite construirea unor clasificatori cu putere de discriminare ridicată, păstrând în același timp un control formal asupra capacității de generalizare.

Rețele neuronale artificiale

Rețelele neuronale artificiale (ANN) reprezintă cea de-a doua direcție majoră în recunoașterea caracterelor din cadrul plăcuțelor de înmatriculare. Spre deosebire de SVM, care își are fundamentul în teoria învățării statistice, ANN-urile sunt inspirate dintr-un model simplificat al activității neuronilor biologici și se bazează pe compunerea ierarhică a unităților elementare derivate din perceptronul lui Rosenblatt [13].

Perceptronul multistrat (MLP), constă într-un strat de intrare, unul sau mai multe straturi ascunse și un strat de ieșire. Fiecare neuron j dintr-un strat efectuează o transformare afină asupra activărilor stratului precedent, urmată de aplicarea unei funcții de activare neliniare σ :

$$a_j = \sigma \left(\sum_i w_{ji} x_i + b_j \right).$$

Compoziția acestor transformări permite rețelei să construiască, în mod implicit, reprezentări ale datelor de complexitate crescândă. Justificarea teoretică pentru această abordare este oferită de teorema aproximării universale, care stabilește că o rețea cu un singur strat ascuns și un număr suficient de neuroni poate aproxima, cu precizie arbitrară, orice funcție continuă definită pe un domeniu compact [20].

Antrenarea ANN-urilor este realizată prin algoritmul de retropropagare a erorii [21], urmat de o actualizare iterativă a acestora prin metode bazate pe coborârea gradien-

tului. În contextul recunoașterii caracterelor de pe plăcuțele de înmatriculare, intrarea este, în mod tipic, o imagine segmentată corespunzătoare unui singur caracter, normalizată la o rezoluție fixă, iar ieșirea reprezintă o distribuție de probabilitate peste setul de clase posibile (literele alfabetului și cifrele 0–9), obținută prin aplicarea funcției softmax.

Comparativ cu SVM, ANN-urile prezintă avantajul de a învăța automat reprezentări intermediare ale datelor, fără a necesita o etapă explicită de inginerie a trăsăturilor. Acest fapt este deosebit de util în prezența variațiilor de font, grosime a caracterelor sau ușoare deformări geometrice. Pe de altă parte, antrenarea ANN-urilor necesită seturi de date considerabil mai voluminoase, este sensibilă la inițializarea parametrilor și nu beneficiază de garanții de generalizare la fel de stricte precum cele derivate din teoria VC pentru SVM-urile cu marjă maximală.

Capitolul 5

Implementarea sistemului

Sistemul propus în lucrarea de față a fost construit pornind de la o arhitectură modulară formată din trei componente cheie: modulul de preluare a datelor (Input Module), fluxul de procesare (Processing Pipeline) și modulul de logică a aplicației (Application Logic Module). Pentru a oferi flexibilitate și a respecta principiile de proiectare extensibilă specifice conceptului de clean code [22], modulul de intrare și cel de logică a aplicației utilizează polimorfismul prin expunerea unor interfețe abstracte.

Această abordare decuplată permite diferitelor aplicații să integreze nucleul sistemului într-un mod elegant, implementând comportamente personalizate și adaptate la mediul de execuție, fără a modifica codul de bază. De exemplu, modulul de intrare poate fi extins pentru a prelua fluxuri video de la o cameră atașată contextului de execuție, fie prin intermediul socket-urilor. În mod similar, modulul de logică a aplicației poate fi personalizat pentru a declanșa acțiuni specifice precum trimiterea unor notificări automate prin e-mail, sau acționarea unor echipamente hardware (ridicarea unei bariere auto), în cazul unui sistem embedded.

În contrast, fluxul de procesare este încapsulat ca o unitate de execuție independentă și de sine stătătoare, neexpunând nicio interfață publică destinată extinderii structurale.

În continuare, acest capitol detaliază tehnologiile utilizate în implementarea aplicației prezentate, dar și o descriere tehnică a fiecărui modul.

5.1 Tehnologii

Alegerea limbajului a fost făcută pe considerente practice așadar, întreg sistemul a fost implementat în Python 3.14.4 în detrimentul unui limbaj compilat precum C++. Această decizie a fost motivată de gradul ridicat de adopție a ecosistemului Python în cadrul sistemelor de tip embedded, precum și de flexibilitatea și viteza de dezvoltare specifice oferite de un limbaj dinamic. De asemenea, librăriile necesare implementării

modului de procesare se bazează pe nuclee scrise în C, optimizate la nivel de instrucțiune.

Pentru a oferi o structură clară, tehnologiile utilizate au fost împărțite în două categorii: cele fundamentale, necesare dezvoltării nucleului sistemului (interfețele menționate anterior și fluxul de procesare), și cele adiționale, specifice dezvoltării aplicației finale.

5.1.1 Nucleu

În etapa de proiectare și dezvoltare a nucleului s-a urmărit minimizarea numărului de dependențe externe. Acest principiu sprijină portabilitatea, permițând adoptarea sistemului în diferite contexte de rulare.

Așadar, tehnologiile de bază sunt:

- OpenCV 4.13.0
- numpy 2.4.2
- scikit-learn 1.8.0
- matplotlib-base 3.10.9

5.1.2 Nivelul de aplicație

După cum am menționat, dependențele necesare dezvoltării aplicației finale sunt opționale, acestea depinzând strict de contextul aplicației dorite. Pentru aplicația propusă, dependențele sunt:

- fastapi 0.135.4
- websockets 15.0.1

5.2 Detalii tehnice

În cele ce urmează va fi prezentată o descriere detaliată a arhitecturii fiecărui modul, abordând aspecte precum interfețele de programare expuse, deciziile de proiectare și implementarea propriu-zisă.

Pentru modulele extensibile, se va realiza o paralelă între implementarea în cadrul unui sistem embedded și implementarea concretă realizată în cadrul aplicației demonstrate.

5.2.1 Input

După cum am menționat anterior, extensibilitatea și portabilitatea au fost principalii factori care au ghidat proiectarea acestui modul. Așadar, am dezvoltat o interfață lipsită de dependențe care expune o singură metodă având semnătura:

```
def get_frame(self) -> Frame:  
    pass
```

Sistem embedded

Aplicație demo

5.2.2 Fluxul de procesare

5.2.3 Nivelul aplicație

Capitolul 6

Concluzii

Concluzii ...

Bibliografie

- [1] Xifan Shi, Weizhong Zhao, and Yonghang Shen. Automatic license plate recognition system based on color image processing. In International conference on computational science and its applications, pages 1159–1168. Springer, 2005.
- [2] Shyang-Lih Chang, Li-Shien Chen, Yun-Chung Chung, and Sei-Wan Chen. Automatic license plate recognition. IEEE transactions on intelligent transportation systems, 5(1):42–53, 2004.
- [3] Rodolfo Zunino and Stefano Rovetta. Vector quantization for license-plate location and image coding. IEEE Transactions on Industrial Electronics, 47(1):159–167, 2002.
- [4] Lin Luo, Hao Sun, Weiping Zhou, and Limin Luo. An efficient method of license plate location. In 2009 First International Conference on Information Science and Engineering, pages 770–773. IEEE, 2009.
- [5] V Karthikeyan and VJ Vijayalakshmi. Localization of license plate using morphological operations. arXiv preprint arXiv:1402.5623, 2014.
- [6] Abbas M Al-Ghaili, Syamsiah Mashohor, Alyani Ismail, and Abdul Rahman Ramli. A new vertical edge detection algorithm and its application. In 2008 international conference on computer engineering & systems, pages 204–209. IEEE, 2008.
- [7] Tran Duc Duan, TL Hong Du, Tran Vinh Phuoc, and Nguyen Viet Hoang. Building an automatic vehicle license plate recognition system. In Proc. Int. Conf. Comput. Sci. RIVF, volume 1, pages 59–63, 2005.
- [8] Jithmi Shashirangana, Heshan Padmasiri, Dulani Meedeniya, and Charith Perera. Automated license plate recognition: a survey on methods and techniques. IEEE Access, 9:11203–11225, 2020.
- [9] Kenji Kanayama, Yoshimasa Fujikawa, Koichi Fujimoto, and Masanobu Horino. Development of vehicle-license number recognition system using real-time image

- processing and its application to travel-time measurement. In [1991 Proceedings] 41st IEEE Vehicular Technology Conference, pages 798–804. IEEE, 1991.
- [10] Tran Duc Duan, TL Hong Du, Tran Vinh Phuoc, and Nguyen Viet Hoang. Building an automatic vehicle license plate recognition system. In Proc. Int. Conf. Comput. Sci. RIVF, volume 1, pages 59–63, 2005.
- [11] Abdulkirim Capar and Muhittin Gokmen. Concurrent segmentation and recognition with shape-driven fast marching methods. In 18th International Conference on Pattern Recognition (ICPR’06), volume 1, pages 155–158. IEEE, 2006.
- [12] Eun Ryung Lee, Pyeoung Kee Kim, and Hang Joon Kim. Automatic recognition of a car license plate using color image processing. In Proceedings of 1st international conference on image processing, volume 2, pages 301–305. IEEE, 1994.
- [13] Frank Rosenblatt. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*, 65(6):386, 1958.
- [14] Vladimir N Vapnik. Pattern recognition using generalized portrait method. *Automation and remote control*, 24(6):774–780, 1963.
- [15] Vladimir N Vapnik. A note on one class of perceptrons. *Automat. Rem. Control*, 25:821–837, 1964.
- [16] Vladimir N Vapnik and A Ya Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. In *Measures of complexity: festschrift for alexey chervonenkis*, pages 11–30. Springer, 2015.
- [17] Nello Cristianini and John Shawe-Taylor. *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. Cambridge University Press, 2000.
- [18] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine learning*, 20(3):273–297, 1995.
- [19] Bernhard E Boser, Isabelle M Guyon, and Vladimir N Vapnik. A training algorithm for optimal margin classifiers. In *Proceedings of the fifth annual workshop on Computational learning theory*, pages 144–152, 1992.
- [20] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural networks*, 2(5):359–366, 1989.
- [21] David E Rumelhart, Geoffrey E Hinton, and Ronald J Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.

- [22] CODE COMPLETE 2nd Edition. WP Publishers & Distributors Pvt Limited, 2004.